



Zipf



$$\underbrace{\log \text{freq}}_y = C - \underbrace{\log \text{rank}}_x$$

1) попутные "нормализованные" слова.



норм. форма

?? став(цы)
 став(ка)
 (цы → ип, ег)
 ка → инфин.

→ лентя (отрезка окончания)

playing → play
 player → plys
 dancing → dance (e)

Анн. Porter Stemmer

- алг, правил отрезания окончаний.

Дан задание I

Нормализуем через морф. анализатор


- берём первый в-т анализа.

morphology 2

- для слова даёт варианты нач. форм, если не знает - угадывает.

Дан задание II

Попытаемся подобрать прямую, проходящую ближе всего к нашим точкам.



Задание Давайте попытаемся предсказать частоту по рангу

Есть примеры (обучающие)

много

ранки	кагора
100	10
20	50
120	?


предсказать

Задача регрессии
непрерывной величины -
задача регрессии

(см. классификация)

Линейная регрессия, предполагает.


$$\underbrace{Y}_{\text{надо предсказать}} = \theta + k \underbrace{X}_{\text{дано}} + \text{Err} \sim N(0, \sigma)$$



Научиться предсказывать = подобрать θ и k .

при подборе делаем так, чтоб $\sum_{i=1}^N \text{err}_i^2 \rightarrow \min$

сумма по примерам.



оц. зел >> оц. красн

Как подобрать прямую?

I. numpy данные с именем лучше хранить в numpy-матрицах.

numpy - создание и работа с матрицами из чисел.

значительно эффективнее и по памяти, и по времени,
по сравнению со списками и циклами.

```
import numpy as np
```

```
x = np.array([10, 20, 30])
```

```
y = np.array([[10, 20], [20, 40]])
```


10	20	30
----	----	----

10	20
20	40

обучаем модель

X_2	y
0	7
1	2
1.5	4
2	3

в zipf



$$\log \text{freq} = C - \log \text{rank}$$

проверке, что получилось ≈ -1

$$\log \text{freq} = b + k \cdot \log \text{rank}$$

$k = -1$

$$\text{freq} = \frac{C}{\text{rank}^{\alpha+1}}$$

N -грамм модель.

Строки модели строки.

] язык - это множество предложений.

Например, в русском

"я еду спать" ∈ Русский

"я еду на сос." ∉ Русский

"мы стали более лучше одевае" ∉ Русский

лучше иначе:

$$P(\text{предложение}) \rightarrow \begin{matrix} \text{значение от } 0 \text{ до } 1 \\ [0, 1] \end{matrix}$$

вероятность встретить предлож.

$$P(\text{"я еду спать"}) \gg P(\text{"я еду на сос"})$$

Для вероятности можем взять $\sum_{w \in \Sigma^n} P(w) = 1$

Это вероятности можем использовать

Можно использовать ($P: \Sigma^n \rightarrow \mathbb{R}$)

значен.

— при генерации текста, выбор нужно делать.

I sit by the table \rightarrow I sit by the table (1)
I sit by the table (2)

$$P(1) > P(2)$$

Выбор так делать.

— можно ошибок.

I sit by the table (1) — было
I sit by the table (2) — и.д.

$P(1) < P(2) \Rightarrow$ и.д. для всех в беге "когда".

У нас будет N-правый марков.

$P(w_1, w_2, w_3, w_4, \dots, w_n) =$ гипотеза: нег слово
зависит от N-1
предыдущих.

$N=2$

$= P(\text{начало} \langle s \rangle w_1, w_2, w_3, \dots, w_n \langle s \rangle \text{конец}) :=$

$= P(w_1 | \langle s \rangle) \cdot P(w_2 | w_1) \cdot P(w_3 | w_2) \cdot \dots \cdot P(\langle s \rangle | w_n).$
вероятность слова
 w_2 после w_1

$$P(A|B) := \frac{P(AB)}{P(B)}$$

ген. б-то

исход

$$P(\text{чет} \geq 3) =$$

$$\frac{P(\text{чет} \geq 3)}{P(\geq 3)} = \frac{2/6}{4/6} = 1/2$$

123456
1/6 1/6 1/6 1/6 1/6 1/6

$$P(\text{чето} | \geq 4) = \frac{P(\text{чето} \geq 4)}{P(\geq 4)} = \frac{1/6 \cdot 12352}{3/6} = 1/3$$

$$P(\text{чето}) = 3/6 = 1/2$$

$N=3$

$$P(\langle s \rangle \langle s \rangle w_1 w_2 w_3 \dots w_n \langle s \rangle) =$$

$$= P(w_1 | \langle s \rangle \langle s \rangle) \cdot P(w_2 | \langle s \rangle w_1) \cdot P(w_3 | w_1 w_2) \cdot$$

$$\dots \cdot P(w_i | w_{i-2} w_{i-1}) \cdot \dots \cdot P(\langle s \rangle | w_n w_n).$$

Как оценить $P(u | w)$? слово u после слова w ?

Метод максимального правдоподобия (MLE)

Дан корпус, где много телесб/предложений/слов.

можно считать $P(\text{корпус}) = P(\text{предг1}) \cdot P(\text{предг2}) \cdot$

$$\text{предположение} \cdot P(\text{предг } n) =$$

$$= P(w_1 | \langle s \rangle) \cdot \dots$$

$\rightarrow \max.$

Max достигается при

$$P(u | w) = \frac{c(wu)}{c(w)}$$

← сколько раз в корпусе дано сочетание слова w , потом u


← сколько слов w в корпусе.

Модель построена.

Дан корпус

→ читаем $P(u|w)$

предположение



$P(\text{предположения})$

$$P(\text{я изумлен}) = P(\text{я} | <s>) \cdot P(\text{изум} | \text{я}) \cdot P(\text{лен} | \text{изум}) \cdot P(|<s> | \text{лен})$$

— $P(u|w) = 0$, если в корпусе нет слова w .

$P(\dots w \dots) = 0$. невозможно иметь 0 вероятностей, они будут часто вычисляться.

Сглаживание — $P(u|w)$ = нужно исправить значение, чтобы всегда $\neq 0$.

P должна остаться вероятностью.

$$\sum_{u \in V} P(u|w) = 1$$

V — весь словарь.

Например

$$P(\text{я} | <s>) + P(\text{он} | <s>) + P(\text{онн} | <s>) + \\ P(\text{стал} | <s>) + \dots + P(\text{ядер} | <s>) = 1$$

для слова.

- как сравнить качество разных сглаживаний?
- в маш. обучении — подбор гиперпараметров
- оценка качества модели

перерыв до 10:45

Пример: Корпус

$N=2$

Результат обучения

- $\langle s \rangle$ я вижу стол $\langle 1s \rangle$
- $\langle s \rangle$ я вижу стул $\langle 1s \rangle$
- $\langle s \rangle$ я вижу стол $\langle 1s \rangle$
- $\langle s \rangle$ я ем стол $\langle 1s \rangle$
- $\langle s \rangle$ я стол $\langle 1s \rangle$

$$\frac{C(\langle s \rangle \langle s \rangle)}{C(\langle s \rangle)} = \frac{C(s \text{ вижу})}{C(s)} = 3$$

$\Sigma=1 \rightarrow$

$$\frac{C(\text{вижу стол})}{C(\text{вижу})} = \frac{1}{3}$$

$w \setminus u$	$\langle s \rangle$	я	вижу	ем	стол	стул	стол	$\langle 1s \rangle$
$\langle s \rangle$	0	1	0	0	0	0	0	0
я	0	0	$3/5$	$1/5$	$1/5$	0	0	0
вижу	0	0	0	0	$1/3$	$1/3$	$1/3$	0
ем	0							
стол	0						1	
стул	0							1
стол	0							1
$\langle 1s \rangle$	0	0	0	0	0	0	0	0

$$P(s \text{ вижу}) = P(s | \langle s \rangle) \cdot P(\text{вижу} | s) \cdot P(\langle s \rangle | \text{вижу}) = 1 \cdot \frac{3}{5} \cdot 0 = 0$$

Удаление от $P(u|u) = 0$

ранее при $\Sigma=1$

$$P(u|u) = \frac{C(u) + \lambda}{C(uu) + \lambda / \Sigma}$$

где $\lambda=1$


$w \setminus u$	$\langle s \rangle$	я	вижу	ем	стол	стул	стол	$\langle 1s \rangle$
$\langle s \rangle$	0	1	0	0	0	0	0	0
я	$1/13$	$1/13$	$4/13$	$2/13$	$2/13$	$1/13$	$1/13$	$1/13$
вижу	0	0	0	0	$1/3$	$1/3$	$1/3$	0
ем	0							
стол	0						1	
стул	0							1
стол	0							1
$\langle 1s \rangle$	0	0	0	0	0	0	0	0

$$\begin{aligned} \frac{0}{5} &\rightarrow \frac{1}{5+1.8} \\ \frac{1}{5} &\rightarrow \frac{2}{5+1.8} \\ \frac{3}{5} &\rightarrow \frac{4}{5+1.8} \end{aligned}$$

При стриживании все неизвестные слова (не из корпуса) заменяются на UNK.

Качество модели. Оценивается на корпусе.

Обычно для оценки корпус не используется



$$\begin{aligned} P(\text{тест. корпус}) &= \\ &= P(\text{пред 1}) \cdot P(\text{пред 2}) \cdot \\ &\quad P(\text{пред 3}) \cdot \dots \rightarrow \max \end{aligned}$$

Perplexity \rightarrow насколько нет D , но \rightarrow with